PROJET DE DIAGNOSTIC AUDIO

Diagnostic acoustique des pannes automobiles

Traitement du signal, extraction de caractéristiques
et comparaison de modèles supervisés et non supervisés

1 386 WAV • 2 772 fenêtres • 6 familles de pannes

Présentation des travaux réalisés — résultats expérimentaux

Objectif et jeu de données

Construire une chaîne audio qui détecte une anomalie puis aide à identifier sa famille.

1 386 enregistrements

WAV mono
13 catégories : normal, panne simple ou combinée.

3 états du moteur

Freinage : 153 WAV
Ralenti : 1 053 WAV
Démarrage : 180 WAV

Labels du dataset

worn_out_brakes · bad_ignition
dead_battery · low_oil
power_steering · serpentine_belt

Point important

Le dataset contient aussi des enregistrements avec plusieurs défauts simultanés.
La formulation du problème change donc selon l'objectif : détection binaire, classe de panne, ou détection indépendante de chaque panne.

De l’enregistrement aux fenêtres audio

Les mêmes réglages de signal sont appliqués avant l’extraction des caractéristiques.

01

Rééchantillonnage

16 kHz

02

Filtre passe-bande

Butterworth, ordre 4
300–7 000 Hz

03

Fenêtrage

1 seconde
50 % de recouvrement

04

Représentation

WPT db4
niveau 4

Résultat : 2 772 fenêtres d’une seconde, issues de 1 386 WAV.

La séparation train / validation / test se fait par enregistrement : les fenêtres d’un même WAV restent ensemble afin de limiter les fuites de données.

65 caractéristiques audio par fenêtre

Combinaison de statistiques temporelles, spectrales et wavelet packet.

12 temporelles

Moyenne, écart-type, RMS
Énergie, ZCR, crête-à-crête
Kurtosis, skewness, crest factor
Maximum, minimum, moyenne absolue

5 spectrales

Centroïde spectral
Bandwidth
Roll-off 85 %
Flatness
Peak ratio

48 wavelet packet

Ondelette db4 au niveau 4
16 sous-bandes
Pour chaque bande : RMS relatif, kurtosis et entropie

12 + 5 + (16 × 3) = 65 caractéristiques

Trois objectifs de classification

Les scores ne sont comparables que si la tâche et les classes évaluées sont identiques.

A — Détection binaire

Question : normal ou anormal ?
XGBoost avec sélection ANOVA ou JSD.
Autoencodeur MLP entraîné seulement sur les sons normaux.

B — Type de panne

Question : quelle catégorie du dataset ?
XGBoost JSD / ANOVA, Random Forest et CNN.
Les pannes combinées constituent des classes distinctes.

C — Spécialistes par panne

Un détecteur binaire par famille de panne.
Les dossiers de pannes combinées comptent comme positifs pour chaque défaut présent.

JSD et ANOVA classent les caractéristiques; ce ne sont pas des classifieurs de panne.

Normal / anormal : XGBoost devant l’autoencodeur

Évaluation sur 278 enregistrements du jeu de test — seuils choisis sur validation.

Modèle	Accuracy	Balanced acc.	Précision anorm.	F1 anormal
XGBoost ANOVA	0,881	0,898	0,971	0,912
XGBoost JSD	0,871	0,898	0,982	0,902
Autoencodeur	0,629	0,718	0,944	0,662

Lecture

ANOVA : F1 anormal supérieur; JSD : précision un peu plus haute.

Autoencodeur

Moins performant ici; peut aider si seules les données normales sont disponibles.

Classification du type de panne

10 catégories anormales, incluant plusieurs configurations combinées — 198 WAV de test.

XGBoost ANOVA

Accuracy 0,601
Balanced accuracy 0,607
Macro-F1 0,616

XGBoost JSD

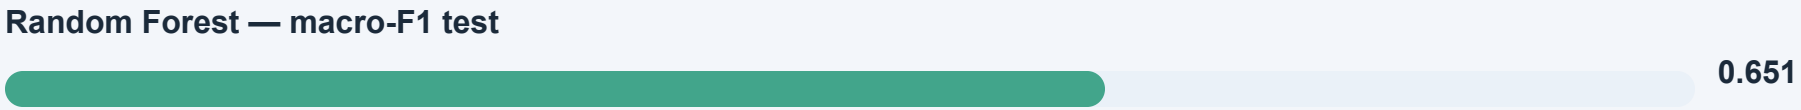
Accuracy 0,596
Balanced accuracy 0,602
Macro-F1 0,615

CNN log-Mel

Accuracy 0,475
Balanced accuracy 0,540
Macro-F1 0,504

Cascade XGBoost ANOVA (détection puis diagnostic) : accuracy 0,622 ; macro-F1 0,559.

Sélection de modèle sur validation : Random Forest (65 variables)

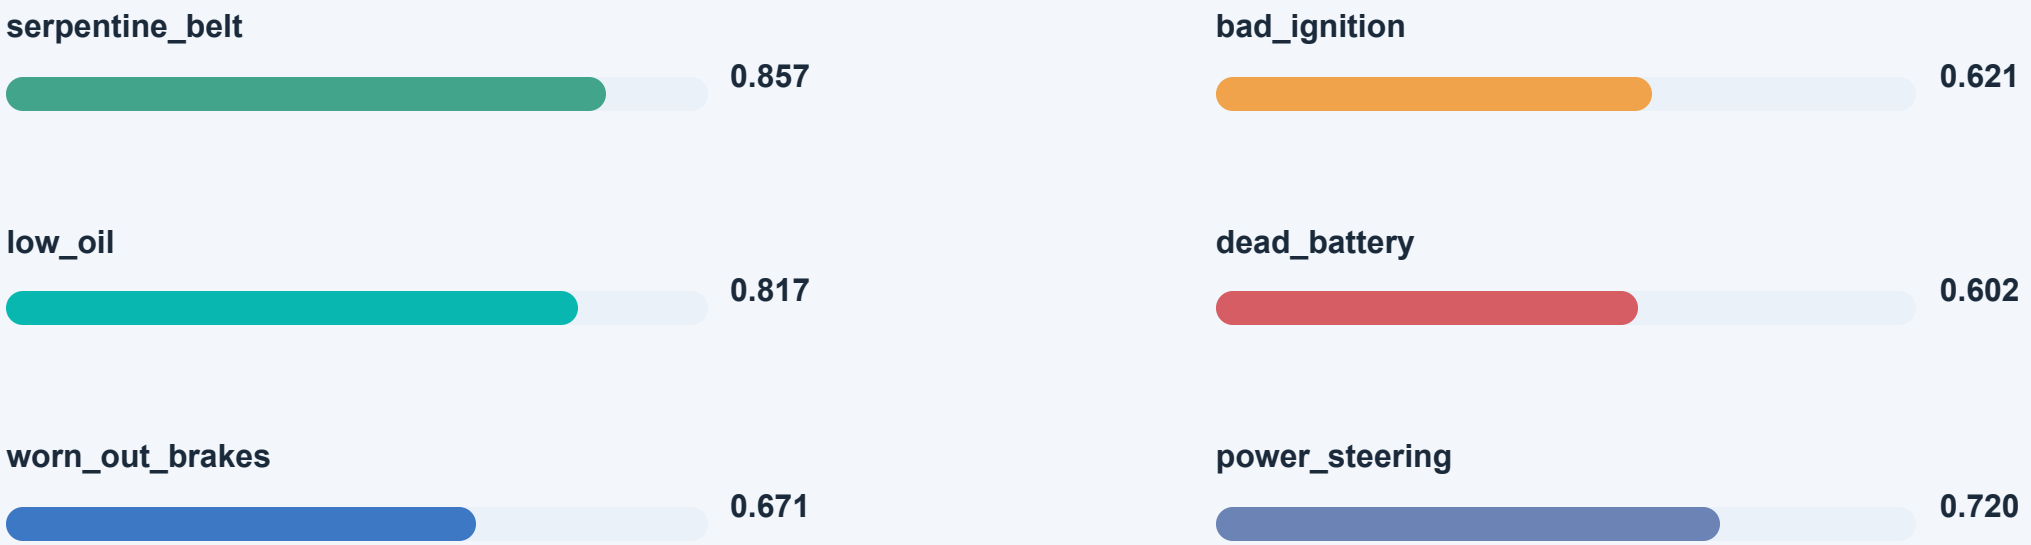


Le Random Forest dépasse légèrement les XGBoost multiclasses dans cette expérience. Les classes combinées et le déséquilibre rendent la tâche difficile.

Comparaison rétrospective : le jeu de test a déjà été utilisé dans des comparaisons antérieures.

Random Forest : résultats par famille de panne

OOF groupé par WAV, avec seuil max-F1 choisi dans la validation interne de chaque fold.



Meilleurs F1 : serpentine_belt et low_oil. Les seuils influencent le compromis entre fausses alertes et pannes manquées.

Du fichier audio à la prédiction

Capture de 30 secondes, fenêtrage, scores des détecteurs, puis CSV par fenêtre.

PC source
Lecture du son

→

Microphone
Capture WAV

→

Random Forest
6 spécialistes

→

Résultat
Scores + seuils

Ce qui fonctionne

Le script enregistre puis prédit; les seuils max-F1 sont appliqués par détecteur.

Limite observée

Le son diffusé par haut-parleur puis capté par un micro diffère du WAV source; des faux positifs ont été observés.

Le prototype micro doit être validé sur plusieurs captures connues avant toute interprétation réelle.

Quel modèle choisir selon l’objectif ?

Les résultats mesurent des tâches différentes; il n’existe pas un classement unique.

Détecter une anomalie

Choix expérimental : XGBoost ANOVA.
F1 anormal : 0,912
Balanced accuracy : 0,898
Résultat sur 278 WAV de test.

Nommer une panne

Random Forest sélectionné par validation.
Macro-F1 test : 0,651
Les spécialistes donnent un F1 par défaut et permettent plusieurs pannes.

Autoencodeur normal-only

Autoencodeur MLP.
F1 anormal : 0,662
Moins bon que XGBoost dans cette expérience, mais adapté à un autre scénario de données.

La détection binaire répond « panne ou non »; le diagnostic répond « quelle panne ? » — les métriques ne se comparent pas directement.

Bilan et prochaines étapes

Acquis

Chaîne audio complète : prétraitement et 65 caractéristiques.
Comparaison binaire, multiclasses, autoencodeur, CNN et spécialistes Random Forest.
Séparation par WAV pour l'évaluation groupée des spécialistes.

À consolider

Évaluer sur un nouveau jeu indépendant.
Ajouter des captures micro étiquetées et variées.
Renforcer les classes rares et analyser les erreurs par panne.
Recalibrer les seuils sans utiliser le jeu de test.

Conclusion : résultats prometteurs pour la détection binaire; l'identification des pannes et l'usage au microphone demandent encore une validation plus robuste.